

Stress-Testing n-step Soft Actor-Critic under Limited Compute

Расширенный отчет по RL final project

Radmir I.

2026

Содержание

1	Abstract	2
2	Введение	2
3	Research question and contribution	2
4	Контекст литературы	3
4.1	Soft Actor-Critic	3
4.2	N-step returns and credit assignment	3
4.3	Off-policy multi-step correction	3
4.4	SACn and T-SAC	4
5	Метод	4
5.1	Standard SAC components	4
5.2	N-step transition buffer	4
5.3	Что фиксируется в ablation	5
6	Experimental setup	5
6.1	Environments	5
6.2	Hyperparameters	5
6.3	Hardware	6
7	Results	6
7.1	Pendulum-v1 sanity check	6
7.2	HalfCheetah-v5 main ablation	6
7.3	Sample-efficiency markers	7
8	Discussion	8
9	Threats to validity	8
9.1	Statistical validity	8
9.2	Algorithmic validity	8
9.3	Hyperparameter fairness	8
9.4	Environment coverage	8
9.5	Compute budget	9
10	Reproducibility checklist	9

11	Future work	9
12	Conclusion	9
	References	10

Коротко. Проект проверяет одну центральную идею из n-step SAC: помогает ли замена стандартного 1-step critic target на n-step target при ограниченном compute. На HalfCheetah-v5 вариант $n = 3$ улучшил обучение относительно baseline, а $n = 5$ провалился при тех же hyperparameters. Главный вывод намеренно узкий: n-step horizon - это параметр стабильности, а не ручка "чем больше, тем лучше".

1 Abstract

This project studies a compact n-step modification of Soft Actor-Critic (SAC) under a limited compute budget. The main question is whether replacing the standard 1-step critic target with n-step targets improves sample efficiency in continuous-control tasks, and where the horizon becomes unstable. I implement a configurable n-step buffer before the replay buffer and compare SAC with $n = 1$, $n = 3$, and $n = 5$. The experiments include Pendulum-v1 as a sanity check and HalfCheetah-v5 as the main benchmark. On HalfCheetah-v5, $n = 3$ reaches the best final return and reaches high-return behavior earlier than the baseline, while $n = 5$ fails under the same hyperparameters. The result suggests that n-step credit assignment can help SAC, but the horizon is a stability parameter rather than a simple bigger-is-better knob.

2 Введение

Soft Actor-Critic (SAC) - сильный off-policy actor-critic алгоритм для задач continuous control. Он использует replay buffer, stochastic actor, twin critics, target networks и maximum entropy objective: policy оптимизирует не только expected return, но и entropy (Haarnoja, Zhou, Abbeel, и др. 2018; Haarnoja, Zhou, Hartikainen, и др. 2018). Поэтому SAC удобен как baseline: он уже достаточно силен, и если небольшое изменение в critic target помогает или ломает обучение, это интересно анализировать.

В стандартном SAC critic обычно обучается по 1-step temporal-difference target. Такой target устойчивый и простой, но информация о reward распространяется назад только на один шаг. N-step returns предлагают более агрессивную идею: накопить несколько rewards перед bootstrap. Это может ускорить credit assignment, особенно если полезное действие влияет на reward не сразу (Sutton и Barto 2018).

Но SAC является off-policy алгоритмом. Transitions в replay buffer могли быть собраны более старой policy. Чем длиннее n-step fragment, тем выше риск off-policy bias и target variance. Именно поэтому n-step SAC - не тривиальная модификация, а вопрос stability/sensitivity (Łyskawa, Lewandowski, и Wawrzyński 2025; Tian, Celik, и Neumann 2025).

Проект не заявляет новый SOTA-алгоритм. Это bounded reproduction и ablation study: я изолирую один механизм - critic target horizon - и проверяю, проявляется ли ожидаемый trade-off в компактной воспроизводимой постановке.

3 Research question and contribution

Главный вопрос проекта:

Помогают ли n-step returns алгоритму SAC при ограниченном compute, и насколько чувствителен результат к выбранному horizon?

Сравнивались три варианта:

Method	Description	Expected behavior
SAC $n = 1$	standard 1-step SAC baseline	stable baseline
SAC $n = 3$	moderate 3-step target	may improve sample efficiency
SAC $n = 5$	longer 5-step target	riskier target

Вклад проекта небольшой, но конкретный:

1. configurable n-step transition buffer, встроенный перед replay buffer;
2. ablation $n = 1/3/5$ на Pendulum-v1 и HalfCheetah-v5;
3. raw logs, plots, summary table и reproduction notes в репозитории;
4. failure analysis для $n = 5$ при фиксированных hyperparameters.

4 Контекст литературы

4.1 Soft Actor-Critic

SAC - off-policy maximum-entropy actor-critic algorithm. Actor оптимизируется не только на expected return, но и на entropy, что помогает exploration и устойчивости. Практическая версия SAC использует twin Q-critics, target networks, replay buffer и automatic entropy temperature tuning (Haarnoja, Zhou, Abbeel, и др. 2018; Haarnoja, Zhou, Hartikainen, и др. 2018).

Для этого проекта SAC подходит как baseline, потому что это сильный continuous-control метод. Если n-step modification помогает или ломает SAC, это не выглядит тривиальным эффектом.

4.2 N-step returns and credit assignment

N-step returns - классическая идея temporal-difference learning. Вместо bootstrap после одного reward алгоритм накапливает несколько rewards и только потом bootstraps:

$$G_t^{(n)} = r_t + \gamma r_{t+1} + \dots + \gamma^{n-1} r_{t+n-1} + \gamma^n V(s_{t+n}).$$

Это может быстрее распространять delayed reward назад. Но target содержит больше sampled rewards и меняет bias-variance trade-off (Sutton и Barto 2018; Sharma и др. 2017).

4.3 Off-policy multi-step correction

Главная сложность - off-policy setting. В replay-based learning более длинные trajectory fragments могли быть собраны behavior policy, отличающейся от текущей policy. Поэтому многие multi-step методы явно вводят correction или trace truncation. Retrace(λ) был предложен как safe and efficient off-policy return-based method (Munos и др. 2016). IMPALA использует V-trace, чтобы стабилизировать off-policy correction в distributed actor-learner setting (Espeholt и др. 2018).

В этом проекте Retrace, V-trace и importance sampling не реализуются. Это сделано намеренно: я тестирую naive n-step SAC, чтобы увидеть чувствительность именно к horizon.

4.4 SACn and T-SAC

SACn напрямую изучает, как соединить Soft Actor-Critic с n-step returns. Его мотивация близка к этому проекту: n-step returns могут ускорить обучение, но обычная комбинация с SAC вносит bias из-за меняющегося action distribution, а importance sampling может быть численно нестабильным (Łyskawa, Lewandowski, и Wawrzyński 2025).

T-SAC / Chunking the Critic идет дальше: он использует trajectory chunks, sequence-aware critic и aggregated n-step targets. Там temporal context становится частью critic learning, а не только scalar target (Tian, Celik, и Neumann 2025).

Этот проект не воспроизводит полный SACn или T-SAC. Он изолирует меньший общий механизм: изменение critic target horizon. Это делает эксперимент выполнимым на limited compute и проще для интерпретации.

5 Метод

5.1 Standard SAC components

Реализация сохраняет стандартную структуру SAC:

- squashed Gaussian actor;
- twin Q-critics;
- target critic networks;
- replay buffer;
- automatic entropy tuning;
- periodic deterministic evaluation.

Critic update использует минимум из двух target critics и entropy term:

$$V_{\text{target}}(s') = \min_i Q_i^{\text{target}}(s', a') - \alpha \log \pi(a'|s').$$

Для обычного 1-step варианта target имеет вид:

$$y_t = r_t + \gamma(1 - d_t)V_{\text{target}}(s_{t+1}).$$

5.2 N-step transition buffer

Единственный алгоритмический компонент, который меняется в основной ablation, - aggregation перед replay buffer. N-step buffer хранит короткую очередь recent transitions. Когда данных хватает, он строит aggregated transition:

```
state      = s_t
action     = a_t
reward_n   = r_t + gamma r_{t+1} + ... + gamma^(k-1) r_{t+k-1}
next_state = s_{t+k}
discount_n = gamma^k
done       = terminal flag inside the n-step window
```

Здесь $k \leq n$. Если episode заканчивается раньше, window обрывается. При $n = 1$ это сводится к обычному SAC.

Critic target становится таким:

$$y_t^{(n)} = R_t^{(n)} + (1 - d_t)\gamma^k V_{\text{target}}(s_{t+k}).$$

Replay buffer поэтому хранит одинаковый тип объектов для всех runs, но reward и discount кодируют разный target horizon.

5.3 Что фиксируется в ablation

Architecture и hyperparameters одинаковые для $n = 1$, $n = 3$, $n = 5$. Это намеренный выбор: эксперимент проверяет именно sensitivity к target horizon.

Это также означает, что сравнение не является полностью tuned для каждого horizon. Возможно, $n = 5$ мог бы стать лучше после отдельного hyperparameter search. Поэтому результат нужно читать как fixed-configuration stability test, а не как доказательство, что $n = 5$ никогда не работает.

6 Experimental setup

6.1 Environments

Использовались две среды:

Environment	Role	Steps	Seed
Pendulum-v1	sanity check	30,000	0
HalfCheetah-v5	main benchmark	100,000	0

Pendulum-v1 - простая continuous-action classic-control среда с action space $\text{Box}(-2.0, 2.0, (1,))$, float32 и observation shape (3,) (Farama Foundation 2026b). HalfCheetah-v5 - MuJoCo locomotion benchmark с action space $\text{Box}(-1.0, 1.0, (6,))$, float32 и observation shape (17,); задача - заставить 2D-робота бежать вперед как можно быстрее (Farama Foundation 2026a).

6.2 Hyperparameters

Parameter	Value
Discount factor gamma	0.99
Target update coefficient tau	0.005
Initial entropy coefficient alpha	0.2
Automatic entropy tuning	yes
Actor learning rate	3e-4
Critic learning rate	3e-4
Alpha learning rate	3e-4
Batch size	256
Replay buffer size	1,000,000
Hidden sizes	[256, 256]
Start steps	5,000
Update after	5,000
Evaluation interval	5,000 steps

Parameter	Value
Evaluation episodes	5
Compared horizons	$n = 1, 3, 5$

Все completed runs используют deterministic evaluation по 5 episodes на checkpoint. Raw CSV logs и plots включены в repository.

6.3 Hardware

Обучение выполнялось на Ryzen 5700 laptop через WSL Ubuntu, CPU training. Это intentionally limited-compute setup. Проект задуман как reproducible student experiment, а не large-scale benchmark.

7 Results

7.1 Pendulum-v1 sanity check

На Pendulum-v1 все три варианта успешно обучаются и приходят к похожему final quality. Главная роль этого эксперимента - проверить, что реализация работает и n-step target construction не ломает SAC на простой среде.




Рис. 1: Pendulum-v1 learning curves

Кривые показывают, что $n = 3$ быстро выходит к хорошему return, но Pendulum-v1 слишком простая среда, чтобы делать сильный вывод о лучшем horizon. Это sanity check, а не основное доказательство.

7.2 HalfCheetah-v5 main ablation

Главный результат получился на HalfCheetah-v5.




Рис. 2: HalfCheetah-v5 learning curves

Method	Final eval return	Best eval return
SAC $n = 1$	4354.49	4354.49
SAC $n = 3$	4578.91	4578.91
SAC $n = 5$	764.49	833.37

Главный результат. В этом single-seed run $n = 3$ дал лучший final return и быстрее вышел к сильному поведению. Вариант $n = 5$ не научился устойчивой running policy при тех же settings.

7.3 Sample-efficiency markers

Final return - не единственная полезная метрика. На HalfCheetah-v5 видно, как быстро варианты доходят до сильного поведения.

Method	Steps to return ≥ 3000	Steps to return ≥ 4000
SAC $n = 1$	65,000	100,000
SAC $n = 3$	45,000	70,000
SAC $n = 5$	not reached	not reached

Эти markers поддерживают чтение графика: $n = 3$ учится быстрее в этом run, а $n = 5$ вообще не достигает high-return behavior.

8 Discussion

Результаты поддерживают ожидаемый trade-off. Moderate n-step horizon может улучшить sample efficiency, потому что reward information быстрее распространяется назад. Вероятно, это объясняет, почему $n = 3$ лучше 1-step baseline на HalfCheetah-v5.

Одновременно более длинный naive target может увеличить off-policy bias и target variance. Это вероятное объяснение провала $n = 5$ при тех же hyperparameters. Самый полезный результат здесь не только то, что $n = 3$ дал лучший final return. Более информативен failure mode $n = 5$: он показывает, что увеличение target horizon может изменить стабильность off-policy SAC.

Самый безопасный вывод узкий: в этом limited-compute single-seed ablation 3-step SAC улучшил HalfCheetah learning по сравнению с 1-step baseline, а 5-step SAC провалился при тех же hyperparameters. Проект не утверждает универсальное превосходство $n = 3$.

Этот failure mode совпадает с мотивацией свежих работ по n-step SAC: n-step targets могут помогать credit assignment, но horizon взаимодействует с off-policy bias, target variance, critic stability и entropy dynamics.

9 Threats to validity

9.1 Statistical validity

Главное ограничение - один seed. Текущий эксперимент полезен как bounded reproduction и ablation evidence, но его недостаточно, чтобы статистически утверждать, что $n = 3$ в целом лучше $n = 1$, или что $n = 5$ в целом проваливается. Более сильная работа должна использовать хотя бы 3-5 seeds и confidence intervals.

9.2 Algorithmic validity

Реализация использует naive n-step targets без off-policy correction. Это сделано намеренно, потому что проект тестирует прямой эффект critic target horizon. Но это также означает, что провал $n = 5$ не нужно считать провалом всех n-step SAC methods. SACn-style correction или sequence-aware critic могли бы стабилизировать longer horizons.

9.3 Hyperparameter fairness

Все horizons используют одинаковые hyperparameters. Это делает ablation чистой, потому что меняется только target horizon. Но это может быть не полностью справедливо к $n = 5$. Более длинный horizon может требовать других learning rates, target smoothing, entropy settings или replay settings.

9.4 Environment coverage

Проект использует Pendulum-v1 и HalfCheetah-v5. Pendulum-v1 - sanity check; она слишком простая для сильных выводов о лучшем horizon. HalfCheetah-v5 - основной benchmark, но одной MuJoCo задачи недостаточно для общего вывода. В future work стоит добавить Hopper-v5, Walker2d-v5 и Ant-v5.

9.5 Compute budget

Все эксперименты запускались на laptop CPU. Это определило дизайн: короткие training budgets, single seed и compact architecture. Проект нужно читать как small reproducible ablation study, а не paper-scale benchmark.

10 Reproducibility checklist

Item	Status
Code committed	yes
Configs committed	yes
Raw CSV logs committed	yes
Plots committed	yes
Summary table committed	yes
Random seed recorded	yes, seed 0
Hardware documented	yes
Limitations documented	yes
Full multi-seed statistics	no

Ключевые repository artifacts:

- implementation: `src/rl/nstep_buffer.py`, `src/rl/sac.py`, `src/train.py`;
- configs: `configs/pendulum_sac_n*.yaml`, `configs/halfcheetah_sac_n*.yaml`;
- raw logs: `results/raw/*.csv`;
- plots: `results/plots/*.png`;
- summary: `results/halfcheetah_summary.csv`;
- slides and notes: `slides/`, `docs/`.

11 Future work

Наиболее полезные продолжения:

1. запустить 3-5 seeds;
2. добавить Hopper-v5, Walker2d-v5 и Ant-v5;
3. посчитать confidence intervals и failure rates;
4. сравнить naive n-step SAC с SACn-style corrections;
5. отдельно tune hyperparameters для каждого horizon;
6. протестировать sequence-aware critics в духе T-SAC.

12 Conclusion

Проект реализует configurable n-step targets в SAC и тестирует их в небольшом, но воспроизводимом ablation. Pendulum-v1 подтверждает, что реализация работает. HalfCheetah-v5 показывает основной trade-off: $n = 3$ помогает, $n = 1$ остается сильным baseline, а $n = 5$ проваливается при тех же hyperparameters.

Итоговая мысль. N-step horizon is a stability parameter, not a bigger-is-better knob.

References

- Espeholt, Lasse, Hubert Soyer, Rémi Munos, Karen Simonyan, Volodymyr Mnih, Tom Ward, Yotam Doron, и др. 2018. «IMPALA: Scalable Distributed Deep-RL with Importance Weighted Actor-Learner Architectures». *arXiv preprint arXiv:1802.01561*. <https://arxiv.org/abs/1802.01561>.
- Farama Foundation. 2026a. «Gymnasium Documentation: HalfCheetah-v5». https://gymnasium.farama.org/environments/mujoco/half_cheetah/.
- . 2026b. «Gymnasium Documentation: Pendulum-v1». https://gymnasium.farama.org/environments/classic_control/pendulum/.
- Haarnoja, Tuomas, Aurick Zhou, Pieter Abbeel, и Sergey Levine. 2018. «Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor». *arXiv preprint arXiv:1801.01290*. <https://arxiv.org/abs/1801.01290>.
- Haarnoja, Tuomas, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, и др. 2018. «Soft Actor-Critic Algorithms and Applications». *arXiv preprint arXiv:1812.05905*. <https://arxiv.org/abs/1812.05905>.
- Łyskawa, Jakub, Jakub Lewandowski, и Paweł Wawrzyński. 2025. «SACn: Soft Actor-Critic with n-step Returns». *arXiv preprint arXiv:2512.13165*. <https://arxiv.org/abs/2512.13165>.
- Munos, Rémi, Tom Stepleton, Anna Harutyunyan, и Marc G. Bellemare. 2016. «Safe and Efficient Off-Policy Reinforcement Learning». *arXiv preprint arXiv:1606.02647*. <https://arxiv.org/abs/1606.02647>.
- Sharma, Sahil, Girish Raguvir J, Srivatsan Ramesh, и Balaraman Ravindran. 2017. «Learning to Mix n-Step Returns: Generalizing Lambda>Returns for Deep Reinforcement Learning». *arXiv preprint arXiv:1705.07445*. <https://arxiv.org/abs/1705.07445>.
- Sutton, Richard S., и Andrew G. Barto. 2018. *Reinforcement Learning: An Introduction*. 2-я изд. MIT Press.
- Tian, Dong, Onur Celik, и Gerhard Neumann. 2025. «Chunking the Critic: A Transformer-based Soft Actor-Critic with N-Step Returns». *arXiv preprint arXiv:2503.03660*. <https://arxiv.org/abs/2503.03660>.